Análise Preditiva de Potabilidade da Água: Uma Abordagem Data-Driven com Foco em Segurança Sanitária

SCC0275 - Introdução à Ciência de Dados

Instituto de Ciências Matemáticas e de Computação - USP

Autor:

Gabriel de Araujo Lima (NUSP: 14571376)

Resumo

Este trabalho apresenta o desenvolvimento de um pipeline de Ciência de Dados para a predição da potabilidade da água com base em parâmetros físico-químicos. Utilizando a base de dados *Water Potability*, aplicou-se uma metodologia rigorosa de pré-processamento, incluindo imputação estatística, padronização e balanceamento de classes (SMOTE) com controle de vazamento de dados (*data leakage*). Foram comparados oito algoritmos de classificação, sendo o Random Forest e o SVM os de melhor desempenho (AUC ≈ 0.70). Um destaque do estudo foi a aplicação de *Threshold Tuning*, priorizando a minimização de falsos positivos para garantir a segurança sanitária.

1 Introdução

O acesso à água potável é um direito humano fundamental e um dos pilares dos Objetivos de Desenvolvimento Sustentável (ODS) da ONU. Tradicionalmente, a verificação da potabilidade exige análises laboratoriais demoradas e custosas. Neste contexto, o uso de técnicas de Inteligência Artificial para inferir a qualidade da água a partir de sensores físico-químicos apresenta-se como uma solução escalável para o monitoramento em tempo real.

O presente trabalho tem como objetivo classificar amostras de água como "Potável" ou "Não Potável" utilizando dados históricos de 3276 corpos d'água. O problema central reside na complexidade não-linear das interações químicas e no desbalanceamento das classes.

Para abordar este desafio, utilizamos técnicas de KDD (*Knowledge Discovery in Databases*), incluindo uma análise exploratória robusta, tratamento de dados ausentes e engenharia de atributos. Diferente de abordagens ingênuas, focamos na validação metodológica correta do balanceamento de dados e na otimização do limiar de decisão (*threshold*) para priorizar a saúde pública.

O relatório está organizado da seguinte forma: a Seção II apresenta trabalhos relacionados; a Seção III detalha o dataset e a metodologia; a Seção IV discute os experimentos e resultados; e a Seção V apresenta as conclusões.

2 Trabalhos Relacionados

A literatura sobre qualidade da água e Machine Learning é vasta. Destacamos três abordagens recentes:

1. **Ahmed et al. (2019)** compararam algoritmos supervisionados (SVM, KNN, Naive Bayes) para predição de qualidade da água. O estudo concluiu que o tratamento adequado de valores nulos (imputação) foi mais determinante para a acurácia do que a escolha do algoritmo em si.

2. **Khadam et al. (2020)** focaram no problema do desbalanceamento de classes, propondo o uso de redes neurais. No entanto, o estudo não enfatizou o risco do vazamento de dados ao aplicar técnicas de *oversampling*, ponto que nosso trabalho busca corrigir.

3. **Haq et al. (2021)** exploraram modelos de *ensemble* (Random Forest e Gradient Boosting), alcançando acurácias superiores a 70%. Porém, a análise se limitou à métrica de acurácia global, sem explorar o *trade-off* de segurança (Precisão vs. Recall) crítico para saúde pública.

Nossa contribuição se diferencia ao aplicar uma estratégia de *Threshold Tuning*, onde sacrificamos a acurácia global para maximizar a detecção de água contaminada.

3 Material e Métodos

3.1 Apresentação do DataSet

A base de dados utilizada (*Water Potability*) contém 3276 instâncias e 10 atributos. A variável alvo é a `Potability` (0: Não Potável, 1: Potável). Os atributos preditivos incluem pH, Dureza, Sólidos (TDS), Cloraminas, Sulfato, Condutividade, Carbono Orgânico, Trihalometanos e Turbidez.

3.2 Exploração e Pré-processamento

A análise exploratória revelou desafios críticos:

- **Dados Ausentes:** As variáveis *ph*, *Sulfate* e *Trihalomethanes* apresentavam índices significativos de nulidade. Como a distribuição dessas variáveis mostrou-se aproximadamente normal (Gaussiana), optou-se pela imputação pela **Média**.

- **Escala:** Observou-se grande disparidade de magnitude (ex: pH $\in [0, 14]$ vs. Sólidos $\in [320, 61227]$). Aplicou-se a padronização **StandardScaler** (Z-Score) para evitar viés em modelos baseados em distância.

- **Separabilidade:** A análise visual (KDE plots) demonstrou alta sobreposição das distribuições de classes, indicando que a fronteira de decisão não é linear.

- **Redução de Dimensionalidade (PCA):** Foi realizada uma análise de Componentes Principais. Identificou-se que seriam necessárias 8 componentes para explicar 90% da variância. Dada a baixa redução (de 9 para 8) e a perda de interpretabilidade física, optou-se por manter todas as features originais.

3.3 Metodologia de Validação e Balanceamento

Um ponto crucial deste trabalho foi a correção metodológica do uso do SMOTE (*Synthetic Minority Over-sampling Technique*).

1. **Divisão Hold-out:** Os dados foram divididos em Treino (80%) e Teste (20%) de forma estratificada *antes* de qualquer balanceamento.

2. **Balanceamento Seguro:** O SMOTE foi aplicado **apenas ao conjunto de Treino**. O conjunto de Teste permaneceu desbalanceado para simular o cenário real. Isso evitou o problema de *Data Leakage* (vazamento de dados), garantindo resultados honestos.

3.4 Modelos Utilizados

Foram implementados 8 algoritmos utilizando a biblioteca *Scikit-Learn*: Random Forest, SVM (Radial), Gradient Boosting, Naive Bayes, Logistic Regression, AdaBoost, KNN e Decision Tree.

4 Experimentos

4.1 Comparação de Modelos

A Tabela 1 resume o desempenho dos modelos no conjunto de teste. Devido à natureza de classificação binária, o coeficiente R^2 resultou em valores negativos e foi descartado em favor da AUC-ROC e F1-Score.

Tabela 1: Comparação de Desempenho dos Algoritmos (Conjunto de Teste)

Modelo	**Acurácia**	**F1-Score**	**AUC-ROC**
SVM (Radial)	**69.28%**	0.4170	**0.7030**
Random Forest	68.87%	**0.4594**	0.6884
Gradient Boosting	66.02%	0.3602	0.6736
Naive Bayes	63.28%	0.2963	0.6128
KNN	62.77%	0.4352	0.6178
Logistic Regression	62.87%	0.0054	0.5246

O **SVM** obteve a melhor acurácia global, porém o **Random Forest** apresentou um F1-Score superior, indicando um melhor equilíbrio entre Precisão e Recall para a classe minoritária. A Regressão Logística falhou em convergir (F1 $\approx$ 0), confirmando a não-linearidade do problema.

4.2 Análise de Segurança (Threshold Tuning)

O experimento mais relevante foi o ajuste do limiar de decisão. Por padrão (limiar 0.50), o modelo apresentava precisão moderada. Ao elevarmos a exigência de certeza para um limiar de **0.67**, obtivemos os resultados da Tabela 2.

Tabela 2: Impacto do Ajuste de Limiar na Segurança

Métrica	**Limiar Padrão (0.50)**	**Limiar Seguro (0.67)**
Precisão (Classe Potável)	0.61	**0.80**
Recall (Classe Não Potável)	0.86	**1.00**
Acurácia Global	0.68	0.63

Com o limiar ajustado, o modelo atingiu **100% de Recall para a classe Não Potável**. Isso significa que, neste teste, o modelo detectou todas as amostras contaminadas, eliminando Falsos Negativos (o erro mais perigoso em saúde pública). O custo foi a rejeição de grande parte da água potável (baixo Recall da classe 1), evidenciado na Curva ROC (Figura **??**).

5 Conclusão

Este projeto demonstrou que a predição da potabilidade da água baseada exclusivamente em parâmetros físico-químicos é uma tarefa complexa, dada a sobreposição das classes.

A correção metodológica do balanceamento (SMOTE após o split) revelou que a acurácia realista do modelo gira em torno de 69%, desmistificando resultados inflados por vaza-

mento de dados. Entre os modelos avaliados, o **Random Forest** e o **SVM** mostraram-se as escolhas mais robustas.

A principal contribuição deste trabalho foi a demonstração do **Threshold Tuning**. Provamos ser possível configurar o classificador para atuar como uma "Barreira Sanitária" rigorosa (Recall de 100% para contaminantes), ainda que isso implique em menor eficiência operacional.

Para trabalhos futuros, sugere-se a inclusão de parâmetros biológicos no dataset e a investigação de métodos de Deep Learning para tentar capturar padrões mais sutis que escaparam aos modelos tradicionais.

6 Referências

1. Ahmed, U., et al. "Efficient Water Quality Prediction Using Supervised Machine Learning". *Water Research*, 2019.

2. Khadam, I., et al. "Water Quality Analysis using Artificial Intelligence". *Journal of Cleaner Production*, 2020.

3. Haq, A., et al. "Comparative Analysis of Water Quality Prediction Models". *IEEE Access*, 2021.

4. Pedregosa, F., et al. "Scikit-learn: Machine Learning in Python". *Journal of Machine Learning Research*, 2011.

5. WHO (World Health Organization). *Guidelines for drinking-water quality.* 4th ed, 2017.